

Parte 2 - CNN e Transfer Learning no Projeto CardioloA

1. Introdução

Este relatório apresenta a comparação entre duas abordagens de classificação de imagens médicas aplicadas ao projeto CardioloA: uma Rede Neural Convolucional (CNN) desenvolvida do zero e uma abordagem baseada em Transfer Learning utilizando o modelo MobileNetV2. A atividade teve como foco avaliar o desempenho dessas técnicas no contexto de imagens de eletrocardiogramas, explorando conceitos de Deep Learning e Visão Computacional aplicados à área da saúde.

2. Objetivo

O objetivo da atividade foi implementar, testar e comparar duas estratégias de classificação de imagens médicas, identificando qual delas apresentou melhor desempenho para o conjunto de dados utilizado no projeto CardioloA.

3. Desenvolvimento

3.1 CNN Desenvolvida do Zero

Inicialmente, foi criada uma Rede Neural Convolucional utilizando as bibliotecas TensorFlow e Keras. A proposta foi desenvolver uma arquitetura específica para o problema de classificação das imagens de eletrocardiogramas.

A arquitetura foi composta por camadas convolucionais, responsáveis pela extração de características das imagens, camadas de pooling, utilizadas para redução da dimensionalidade, e camadas densas, responsáveis pela etapa final de classificação.

Após o treinamento, a CNN apresentou excelente desempenho, atingindo aproximadamente 99,67% de acurácia durante o treinamento e 100% de acurácia no conjunto de teste.

Além da acurácia, as métricas de precisão, recall e F1-Score também apresentaram resultados elevados para todas as classes analisadas, indicando boa capacidade de generalização dentro do conjunto avaliado.

3.2 Transfer Learning com MobileNetV2

Como segunda abordagem, foi utilizado Transfer Learning por meio do modelo pré-treinado MobileNetV2. Essa técnica permite aproveitar conhecimentos previamente aprendidos por modelos treinados em grandes bases de imagens, reduzindo o tempo necessário para o treinamento e facilitando a aplicação em novos problemas.

No entanto, apesar de ser uma técnica amplamente utilizada, o desempenho do MobileNetV2 foi inferior ao obtido pela CNN desenvolvida especificamente para o problema.

Para este conjunto de dados específico de eletrocardiogramas, a abordagem com Transfer Learning apresentou aproximadamente 63% de acurácia no conjunto de teste.

4. Comparação dos Resultados

A comparação dos resultados demonstrou que a CNN desenvolvida do zero apresentou melhor capacidade de classificação para as imagens utilizadas no projeto. Enquanto a CNN alcançou cerca de 100% de acurácia no conjunto de teste, o modelo MobileNetV2 obteve aproximadamente 63%.

Uma possível explicação para esse resultado é que o conjunto de dados possui características bastante específicas. Dessa forma, uma arquitetura personalizada conseguiu aprender melhor os padrões presentes nos exames analisados.

Por outro lado, o MobileNetV2 foi originalmente treinado para imagens genéricas, o que pode ter limitado sua eficiência em um cenário específico de imagens médicas de eletrocardiogramas.

Abordagem	Modelo utilizado	Acurácia no teste	Observação
CNN desenvolvida do zero	Arquitetura personalizada	Aproximadamente 100%	Melhor desempenho para o conjunto analisado
Transfer Learning	MobileNetV2	Aproximadamente 63%	Desempenho inferior no dataset específico

5. Conclusão

As duas abordagens foram implementadas com sucesso e permitiram avaliar diferentes estratégias de Visão Computacional aplicadas à área da saúde. Os resultados demonstraram que a CNN personalizada apresentou desempenho superior para o conjunto de dados utilizado.

Embora o Transfer Learning com MobileNetV2 tenha servido como importante referência de comparação, sua performance foi limitada pelas características específicas das imagens de eletrocardiogramas. Assim, a atividade evidenciou a importância de escolher a arquitetura mais adequada ao tipo de dado e ao objetivo do projeto.

Conclui-se que a CNN desenvolvida do zero foi a abordagem mais eficiente neste estudo, permitindo aplicar de forma prática conceitos de Deep Learning, Redes Neurais Convolucionais e Transfer Learning no apoio à análise de exames cardiológicos.